



# GARBAGE CLASSIFICATION

Un Proyecto de Aprendizaje Automático  
para un Futuro Sostenible

DataSet: Garbage Classification (Kaggle)

# Introducción: El Desafío de la Clasificación de Residuos con IA

## El Problema Real



La separación manual en plantas de reciclaje es lenta, costosa y propensa a errores.  
La Inteligencia Artificial ofrece una solución automatizada.

## El Dataset: Garbage Classification



Origen: Kaggle.  
Tamaño: ~2,500 imágenes.  
Clases: Cartón, Vidrio, Metal, Papel, Plástico, Basura General.

## Por Qué Este Proyecto



Un problema cotidiano y un reto ideal para construir una Red Neuronal Convolucional (CNN) desde cero, sin necesidad de superordenadores.

# Los Retos del Dataset: Análisis de Datos

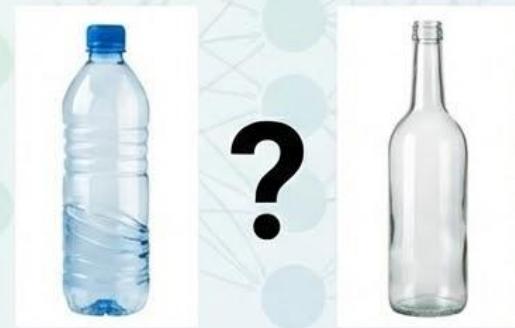
## Desbalanceo de Clases



Muchas fotos de papel, pocas de basura general.

"El modelo tenía a apostar por lo seguro y predecir siempre las clases mayoritarias."

## Duplicados y Similitudes Ópticas



Limpieza de fotos repetidas y el gran reto de la similitud.

"Distinguir una botella de plástico transparente de una de cristal en una foto es difícil hasta para un humano."

# Los Pasos y la Metodología: La Receta

## Paso 1: Data Augmentation (Como una Receta)



2,500 fotos son pocas. Usé técnicas para rotar, hacer zoom y voltear las imágenes.

Así evité que la red se aprendiera las fotos de memoria (overfitting).

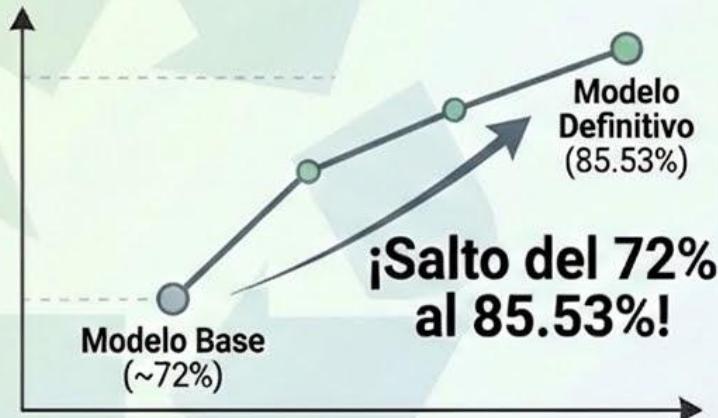
## Paso 2: La Evolución de la Red (Ablation Study)



Empezó inestable (~72%).  
Probé pesos de clases.  
El Gran Descubrimiento:  
BatchNormalization (estabilizar) + Dropout  
(forzar aprendizaje) = Modelo Definitivo.

# Resultados y lo más Interesante del Proyecto

## Ablation Study: El Salto de Calidad



Orgullosos del progreso: del 72% inicial a un 85.53% de precisión.

## Matriz de Confusión (El Momento Clave)

	Papel	Cartón	Plástico	Vidrio
Papel	✓			
Cartón		✓		
Plástico			?	?
Vidrio			?	?

Casi perfecto en Papel y Cartón.  
Confusión entre Plástico y Vidrio.

Lejos de ser un fallo, este error demuestra que el modelo está aprendiendo características visuales reales, ya que ambos materiales comparten transparencias y reflejos de luz.

# 5. El Despliegue (El "Bonus")

Del Colab al Mundo Real: ¡Una Aplicación para Todos!



Exportamos el archivo .keras,  
liberando al modelo de Colab.



Creamos una **interfaz web visual**  
con **Streamlit**. ¡Cualquier persona  
puede probarla!

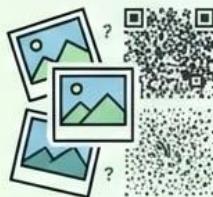


Una herramienta real y accesible para la detección de materiales, no solo código.

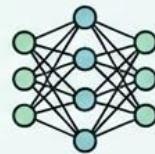
# 6. Conclusiones y Futuro



## Qué Hemos Aprendido (Lo Esencial)



Filtro BatchNormalization

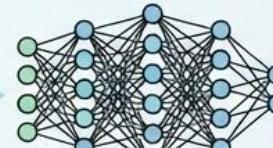


**¡La Calidad es Clave!** Limpiar los datos y estabilizar el entrenamiento con **BatchNormalization** es mucho más efectivo que simplemente aumentar el tamaño de la red. La **preparación** inteligente supera la fuerza bruta.

La experimentación y la comprensión de los datos son fundamentales para el éxito en IA.



## Futuro (Próximos Pasos)



Meta: >90% Precisión

Transfer Learning (Google/Microsoft)

Usar **Transfer Learning** para aprovechar redes de vanguardia y superar la barrera del 90%.



Recopilar más fotos con fondos y condiciones reales para mejorar la generalización del modelo.